

一、项目简介

版本：v0.2 改进版 | EDA + SMOTE + GridSearchCV + 消融实验 + 46 单元测试

本项目使用机器学习方法，基于电信客户的基本信息、消费行为和服务使用情况，预测客户是否存在流失风险。项目对比了三种常用算法（逻辑回归、随机森林、XGBoost），通过 SMOTE 处理数据不均衡，GridSearchCV 超参数调优，并输出可视化图表帮助理解分析结果。

当前进度

数据获取 已完成 | EDA 分析 已完成 | 数据清洗 已完成 | 特征工程 已完成
SMOTE 过采样 已完成 | GridSearchCV 调优 已完成 | 消融实验 已完成
单元测试 已完成 (46 tests) | 论文撰写 待做 | PPT 制作 待做

数据集说明

数据来源：Kaggle 公开数据集「Telco Customer Churn」

数据规模：7,043 条客户记录，包含 20 个特征字段

特征包括：性别、年龄、是否退休、入网时长、服务订阅情况、合同类型、支付方式、月费用、总费用等

预测目标：客户是否流失（Churn：是/否）

你将得到什么

- 模型对比表：三种算法的准确率、召回率、F1 分数、AUC
- EDA 探索分析图：数据分布、类别特征流失率、相关性热力图
- 客户流失分布图（饼图）
- 特征重要性排序图（哪些因素最影响流失）
- ROC 曲线对比图（模型性能可视化）
- 混淆矩阵图（预测正确/错误的数量分布）
- 消融实验对比表（各模块贡献量化）

二、环境准备（只需做一次）

2.1 安装 Python

本项目需要 Python 3.8 或更高版本。如果电脑上已有 Python，可跳过此步骤。

- 打开浏览器，访问：<https://www.python.org/downloads/>
- 点击黄色按钮 "Download Python" 下载安装包
- 运行下载的 .exe 文件，安装时务必勾选 [x] Add Python to PATH
- 点击 Install Now，等待安装完成

[注意] 安装时一定要勾选「Add Python to PATH」，否则后续命令行无法识别 python 命令。

2.2 如何进入项目目录（重要）

拿到项目文件夹后，首先需要让命令行切换到该目录下。根据你的存放位置，选择以下任意一种方法：

方法一：拖拽文件夹（推荐，最简单）

- 按 Win+R，输入 cmd，回车打开命令行窗口
- 输入 cd 加一个空格（注意空格！）：

```
cd
```

- 打开文件资源管理器，找到你存放的项目文件夹
- 用鼠标将整个项目文件夹拖入命令行窗口
- 此时命令行会自动填上文件夹的完整路径，例如：

```
cd C:\Users\你的用户名\Desktop\医疗大数据综合应用实验
```

- 按回车，即进入项目目录

方法二：右键打开（Win11 推荐）

- 在文件资源管理器中，打开项目文件夹
- 点击地址栏，输入 cmd，回车
- 命令行窗口将自动定位到当前目录

[注意] 进入项目目录后，后续所有命令都在该窗口执行，不要关闭。你可以用 `dir` 命令确认当前目录下是否有 `src`、`data` 等文件夹。

2.3 验证 Python 安装

在命令行窗口中输入以下命令并回车：

```
python --version
```

- 如果显示 "Python 3.x.x" 则表示安装成功

2.4 安装项目依赖

确保命令行已进入项目目录（参考 2.2 节），然后执行：

```
pip install -r requirements.txt
```

等待安装完成（约 2-5 分钟，因网络速度而异）。看到 Successfully installed 即表示成功。

[注意] 如果安装速度很慢，可以试试：`pip install -r requirements.txt -i https://pypi.tuna.tsinghua.edu.cn/simple`

[注意] 本项目已自带中文字体（assets/fonts/NotoSansSC.ttf），图表中文标注在 Windows/Mac/Linux 下均可正常显示，无需额外安装字体。

三、运行项目

3.1 准备数据

数据集文件需要提前下载并放置到指定目录。（通常已由项目负责人准备好）

- 确认 `data/raw/` 目录下存在 `WA_Fn-UseC_-Telco-Customer-Churn.csv` 文件
- 如果缺少该文件，请从以下地址下载：

```
https://www.kaggle.com/datasets/blastchar/telco-customer-churn
```

- 下载后解压，将 `.csv` 文件放入 `data/raw/` 目录

3.2 一键运行

确保命令行已进入项目目录（参考 2.2 节），然后执行：

```
python src/main.py
```

程序运行后将自动完成以下步骤：

- 加载并清洗数据（处理缺失值）
- 特征工程（编码、标准化、划分训练/测试集）
- 训练三个模型（逻辑回归、随机森林、XGBoost）
- 交叉验证评估模型稳定性
- 在测试集上对比模型性能
- 生成 4 张可视化图表到 `results/` 目录

整个流程约 10-30 秒完成。

四、结果说明

4.1 控制台输出

程序运行过程中，命令行窗口会实时显示处理进度和模型评估结果。重点关注最后的模型对比表：

Model	Accuracy	Precision	Recall	F1	AUC
LogisticRegression	0.8048	0.6581	...	...	0.8426
RandomForest	0.7906	0.6561	...	...	0.8429
XGBoost	0.7935	0.6379	...	...	0.8363
最佳模型: RandomForest (AUC=0.8429)					

各项指标含义：

- Accuracy（准确率）：预测正确的比例，越高越好
- Precision（精确率）：预测为流失的客户中，真正流失的比例
- Recall（召回率）：真正流失的客户中，被模型找出的比例
- F1：精确率和召回率的调和平均，综合衡量模型效果
- AUC：模型区分流失/非流失客户的能力，越接近 1 越好

4.2 可视化图表（results/ 目录）

以下 4 张图片在程序运行后自动生成，可直接双击打开查看：

① churn_distribution.png — 客户流失分布

饼图展示数据集中流失客户与留存客户的比例，直观了解数据失衡程度。

② feature_importance.png — 特征重要性排序

横向条形图，展示哪些因素对预测客户流失最重要。排名越靠前，影响越大。

③ roc_curves.png — ROC 曲线对比

三条曲线分别对应三种模型。曲线越靠近左上角，模型性能越好。

对角线（虚线）代表随机猜测的基线，AUC 值标注在图例中。

④ confusion_matrices.png — 混淆矩阵

每个模型一个热力图，展示预测结果与真实结果的交叉统计。

左上=正确预测未流失；右下=正确预测流失；右上=误报；左下=漏报。

五、常见问题

Q1：提示 "python 不是内部或外部命令"

Python 未正确安装或未添加到 PATH。请重新运行 Python 安装包，选择「Modify」，确保勾选「Add Python to environment variables」，然后重启命令行窗口。

Q2：pip install 报错或连接超时

网络问题导致无法从默认源下载。使用国内镜像源重试：

```
pip install -r requirements.txt -i https://pypi.tuna.tsinghua.edu.cn/simple
```

Q3：提示找不到数据文件

请确认 `data/raw/` 目录下存在 `WA_Fn-UseC_-Telco-Customer-Churn.csv` 文件。文件名必须完全一致（含大小写），不能是中文名或带有（1）等后缀。

Q4：运行时出现红色的错误信息

截图保存错误信息，联系项目工程负责人排查。常见原因：Python 版本太低（需 ≥ 3.8 ）、依赖包未完整安装、数据文件损坏。

Q5：生成的图片中文显示为方框

项目已配置使用系统自带的中文字体。如果出现方框，通常是因为系统字体版本问题，可联系项目负责人处理。

Q6：想修改模型参数或重新训练

编辑 `configs/config.yaml` 文件（可用记事本打开），修改相关参数后重新运行即可。建议在修改前备份原文件。

附录：项目文件结构

项目根目录/	
├── README.md	项目说明文档
├── 使用说明.pdf	本文件（操作指南）
├── requirements.txt	Python 依赖列表
├── configs/config.yaml	配置文件（随机种子、模型参数）
├── src/main.py	程序入口（运行此文件即可）
├── data/raw/	原始数据存放目录
├── results/	输出结果（图片）
└── notebooks/	Jupyter 探索笔记（进阶用户）