

一、项目介绍

1.1 做什么的

用电脑分析电信客户数据，找出哪些客户可能会取消服务(流失)。使用逻辑回归、随机森林、XGBoost 三种方法，比较哪种预测最准，最后生成图表。

1.2 为什么做

医疗大数据综合应用实验课程期末项目。电信公司如果提前发现高风险客户就可以挽留，降低运营成本。

1.3 当前版本 v0.2

- 数据清洗：7043 条记录，修复缺失值
- EDA 探索分析：多角度观察数据，发现关键因素
- 特征工程 + SMOTE：解决数据不均衡问题
- 三模型 + GridSearchCV 自动调优
- 消融实验：量化各模块贡献
- 46 个单元测试，70% 代码覆盖

1.4 数据

Kaggle 公开数据集 Telco Customer Churn。7043 条，20 个特征：性别、年龄、入网时长、服务订阅、合同类型、支付方式、月费/总费等。不含个人隐私。

二、跑起来

第一步：安装 Python

检查是否已有 Python。按 Win+R，输入 cmd 回车，在黑色窗口输入：

```
python --version
```

看到 Python 3.x.x 说明已有，跳到第二步。否则：

- 打开 <https://www.python.org/downloads/>
- 下载安装包，双击运行
- 安装时务必勾选 Add Python to PATH

[注意] Add Python to PATH 这一步最关键，不勾选后续命令无法识别 python。

第二步：进入项目目录

方法一(推荐)：Win+R 打开 cmd，输入 cd 加空格，把项目文件夹拖进窗口，回车。

方法二：打开项目文件夹，点击地址栏，输入 cmd 回车。

确认：输入 dir 回车，应看到 src、data、README.md 等。

第三步：安装依赖

```
pip install -r requirements.txt
```

等待 2-5 分钟，看到 Successfully installed 即完成。

[提示] 速度慢换清华源：pip install -r requirements.txt -i <https://pypi.tuna.tsinghua.edu.cn/simple>

[提示] 项目自带中文字体(assets/fonts/NotoSansSC.ttf)，任何电脑图表中文都能正常显示。

检查数据文件

确认 data/raw/ 下有 WA_Fn-UseC-Telco-Customer-Churn.csv。没有的话从 Kaggle 下载放入。

[注意] 文件名必须完全一致，不要改名或加后缀。

三、运行

3.1 完整运行(约3-5分钟)

```
python src/main.py
```

自动完成：加载数据 -> 清洗 -> 特征工程 -> SMOTE -> 训练 -> GridSearchCV 调优 -> 交叉验证 -> 测试评估 -> 出图 -> 存记录。全程自动。

3.2 EDA 图表

```
python scripts/eda_charts.py
```

生成 4 张数据探索图到 results/。

3.3 消融实验

```
python scripts/ablation.py
```

对比四组配置，输出各模块贡献表。

3.4 单元测试

```
python -m pytest tests/ -v
```

46 个测试，全绿 passed 说明一切正常。

四、看懂结果

4.1 命令行输出

加载数据

显示 7043 行数据、缺失值数量、填充方式。Churn 占比约 26.5%，流失:留存约 1:3，数据不均衡。

特征工程

自动剔除冗余特征(如 TotalCharges 与 MonthlyCharges 高度相关)。SMOTE 过采样：流失样本从 1308 条扩充到 3621 条。

GridSearchCV

每个模型自动尝试几十到上百种参数组合，找最优那组。这步最耗时(3-5分钟)。

最终对比表

模型	准确率	精确率	召回率	F1	AUC
逻辑回归	0.7431	0.5109	0.7540	0.6091	0.8364
随机森林	0.7693	0.5671	0.5535	0.5602	0.8219
XGBoost	0.7842	0.5936	0.5936	0.5936	0.8282

通俗解释：

- 准确率 Accuracy：猜对的比例，越高越好
- 精确率 Precision：预测会流失的人里，真的流失了多少
- 召回率 Recall：真的流失的人里，被模型发现了多少 - 本项目最关注
- F1：精确和召回的综合平衡分
- AUC：模型区分能力，0.8 不错，0.9 以上优秀

4.2 结果图表

主流程 4 张图(python src/main.py)

- churn_distribution.png：流失分布饼图
- feature_importance.png：特征重要性排序，越长越重要
- roc_curves.png：ROC曲线，越靠左上角越好
- confusion_matrices.png：预测正确/错误的数量

EDA 4 张图(python scripts/eda_charts.py)

- eda_churn_distribution.png：流失分布
- eda_numerical.png：数值特征分组对比
- eda_categorical.png：类别特征流失率

- eda_correlation.png: 相关性热力图

4.3 实验记录

- results/experiments.csv: 每次运行自动记录(可用Excel打开)
- results/ablation.csv: 消融实验四组对比

五、常见问题

Q1: python 不是内部或外部命令

Python 没装或没勾选 Add to PATH。重装并勾选。关掉命令行重开。

Q2: pip install 慢/报错

换清华源: `pip install -r requirements.txt -i https://pypi.tuna.tsinghua.edu.cn/simple`。不行换手机热点。

Q3: 找不到数据文件

检查 data/raw/ 下是否有 WA_Fn-UseC_-Telco-Customer-Churn.csv。文件名必须完全一致。不要改名。

Q4: 运行时红色报错

截图保存错误信息(从最后一行往上截)，联系技术负责人。常见原因：依赖没装全、数据文件损坏、Python版本太低。

Q5: 图表中文是方框乱码

项目自带 NotoSansSC.ttf 开源字体，任何系统都应正常。如仍异常，重新 clone 完整项目代码。

Q6: 想改配置关闭SMOTE等

用记事本打开 configs/config.yaml:

- imbalance.method 改为 none 关闭 SMOTE
- features.selection_method 改为 none 关闭特征选择
- grid_search.enabled 改为 false 跳过 GridSearchCV

保存后重新运行。改前备份原文件。

Q7: 跑一半卡住了

GridSearchCV 需 3-5 分钟，屏幕持续输出，正常。其他阶段卡住按 Ctrl+C 停止，检查数据文件后重试。

Q8: 结果和别人不一样

项目用固定随机种子(seed=42)，配置相同结果应该一样。不一样说明数据或config.yaml不一致。

附录：文件结构

README.md	项目总览和快速开始
使用说明.pdf	本文件
requirements.txt	Python 依赖列表
configs/config.yaml	配置：seed、SMOTE、GridSearchCV
data/raw/	原始数据存放目录
src/main.py	主入口，一键运行
src/data.py	数据加载与清洗
src/features.py	特征工程 + SMOTE
src/models.py	模型训练 + GridSearchCV
src/evaluate.py	评估指标计算
src/visualize.py	图表生成
src/tracking.py	实验记录 CSV
scripts/eda_charts.py	EDA 图表生成
scripts/ablation.py	消融实验
tests/	46 个单元测试
results/	输出图表 + CSV
assets/fonts/	开源中文字体

术语速查

术语	通俗解释
EDA	建模前先看看数据什么样
SMOTE	自动生成少数样本解决不均衡
GridSearchCV	自动尝试参数组合找最优
消融实验	逐项关功能看贡献多大
Recall	真正流失的人中被发现的比例
AUC	模型区分能力，越接近1越好