

一、项目简介

版本：基础跑通版本 v0.1 | 全流程可运行，模型调优与深度分析待后续迭代

本项目使用机器学习方法，基于电信客户的基本信息、消费行为和服务使用情况，预测客户是否存在流失风险。项目对比了三种常用算法（逻辑回归、随机森林、XGBoost），并输出可视化图表帮助理解分析结果。

当前进度

数据获取 已完成 | 数据清洗 已完成 | 特征工程 已完成 | 模型训练 已完成 | 模型评估 已完成
模型调优 待做 | 深度分析 待做 | 论文撰写 待做

数据集说明

数据来源：Kaggle 公开数据集「Telco Customer Churn」

数据规模：7,043 条客户记录，包含 20 个特征字段

特征包括：性别、年龄、是否退休、入网时长、服务订阅情况、合同类型、支付方式、月费用、总费用等

预测目标：客户是否流失（Churn：是/否）

你将得到什么

- 模型对比表：三种算法的准确率、召回率、F1 分数、AUC
- 客户流失分布图（饼图）
- 特征重要性排序图（哪些因素最影响流失）
- ROC 曲线对比图（模型性能可视化）
- 混淆矩阵图（预测正确/错误的数量分布）

二、环境准备（只需做一次）

2.1 安装 Python

本项目需要 Python 3.8 或更高版本。如果电脑上已有 Python，可跳过此步骤。

- 打开浏览器，访问：<https://www.python.org/downloads/>
- 点击黄色按钮 "Download Python" 下载安装包
- 运行下载的 .exe 文件，安装时务必勾选 [x] Add Python to PATH
- 点击 Install Now，等待安装完成

[注意] 安装时一定要勾选「Add Python to PATH」，否则后续命令行无法识别 python 命令。

2.2 如何进入项目目录（重要）

拿到项目文件夹后，首先需要让命令行切换到该目录下。根据你的存放位置，选择以下任何一种方法：

方法一：拖拽文件夹（推荐，最简单）

- 按 Win+R，输入 cmd，回车打开命令行窗口
- 输入 cd 加一个空格（注意空格！）：

```
cd
```

- 打开文件资源管理器，找到你存放的项目文件夹
- 用鼠标将整个项目文件夹拖入命令行窗口
- 此时命令行会自动填上文件夹的完整路径，例如：

```
cd C:\Users\你的用户名\Desktop\医疗大数据综合应用实验
```

- 按回车，即进入项目目录

方法二：右键打开（Win11 推荐）

- 在文件资源管理器中，打开项目文件夹
- 点击地址栏，输入 cmd，回车
- 命令行窗口将自动定位到当前目录

[注意] 进入项目目录后，后续所有命令都在该窗口执行，不要关闭。你可以用 `dir` 命令确认当前目录下是否有 `src`、`data` 等文件夹。

2.3 验证 Python 安装

在命令行窗口中输入以下命令并回车：

```
python --version
```

- 如果显示 "Python 3.x.x" 则表示安装成功

2.4 安装项目依赖

确保命令行已进入项目目录（参考 2.2 节），然后执行：

```
pip install -r requirements.txt
```

等待安装完成（约 2-5 分钟，因网络速度而异）。看到 Successfully installed 即表示成功。

[注意] 如果安装速度很慢，可以试试：`pip install -r requirements.txt -i https://pypi.tuna.tsinghua.edu.cn/simple`

三、运行项目

3.1 准备数据

数据集文件需要提前下载并放置到指定目录。（通常已由项目负责人准备好）

- 确认 `data/raw/` 目录下存在 `WA_Fn-UseC_-Telco-Customer-Churn.csv` 文件
- 如果缺少该文件，请从以下地址下载：

```
https://www.kaggle.com/datasets/blastchar/telco-customer-churn
```

- 下载后解压，将 `.csv` 文件放入 `data/raw/` 目录

3.2 一键运行

确保命令行已进入项目目录（参考 2.2 节），然后执行：

```
python src/main.py
```

程序运行后将自动完成以下步骤：

- 加载并清洗数据（处理缺失值）
- 特征工程（编码、标准化、划分训练/测试集）
- 训练三个模型（逻辑回归、随机森林、XGBoost）
- 交叉验证评估模型稳定性
- 在测试集上对比模型性能
- 生成 4 张可视化图表到 `results/` 目录

整个流程约 10-30 秒完成。

四、结果说明

4.1 控制台输出

程序运行过程中，命令行窗口会实时显示处理进度和模型评估结果。重点关注最后的模型对比表：

Model	Accuracy	Precision	Recall	F1	AUC
LogisticRegression	0.8048	0.6581	...	...	0.8426
RandomForest	0.7906	0.6561	...	...	0.8429
XGBoost	0.7935	0.6379	...	...	0.8363
最佳模型： RandomForest (AUC=0.8429)					

各项指标含义：

- Accuracy（准确率）：预测正确的比例，越高越好
- Precision（精确率）：预测为流失的客户中，真正流失的比例
- Recall（召回率）：真正流失的客户中，被模型找出的比例
- F1：精确率和召回率的调和平均，综合衡量模型效果
- AUC：模型区分流失/非流失客户的能力，越接近 1 越好

4.2 可视化图表（results/ 目录）

以下 4 张图片在程序运行后自动生成，可直接双击打开查看：

① churn_distribution.png — 客户流失分布

饼图展示数据集中流失客户与留存客户的比例，直观了解数据失衡程度。

② feature_importance.png — 特征重要性排序

横向条形图，展示哪些因素对预测客户流失最重要。排名越靠前，影响越大。

③ roc_curves.png — ROC 曲线对比

三条曲线分别对应三种模型。曲线越靠近左上角，模型性能越好。

对角线（虚线）代表随机猜测的基线，AUC 值标注在图例中。

④ confusion_matrices.png — 混淆矩阵

每个模型一个热力图，展示预测结果与真实结果的交叉统计。

左上=正确预测未流失；右下=正确预测流失；右上=误报；左下=漏报。

五、常见问题

Q1：提示 "python 不是内部或外部命令"

Python 未正确安装或未添加到 PATH。请重新运行 Python 安装包，选择「Modify」，确保勾选「Add Python to environment variables」，然后重启命令行窗口。

Q2：pip install 报错或连接超时

网络问题导致无法从默认源下载。使用国内镜像源重试：

```
pip install -r requirements.txt -i https://pypi.tuna.tsinghua.edu.cn/simple
```

Q3：提示找不到数据文件

请确认 `data/raw/` 目录下存在 `WA_Fn-UseC_-Telco-Customer-Churn.csv` 文件。文件名必须完全一致（含大小写），不能是中文名或带有（1）等后缀。

Q4：运行时出现红色的错误信息

截图保存错误信息，联系项目工程负责人排查。常见原因：Python 版本太低（需 ≥ 3.8 ）、依赖包未完整安装、数据文件损坏。

Q5：生成的图片中文显示为方框

项目已配置使用系统自带的中文字体。如果出现方框，通常是因为系统字体版本问题，可联系项目负责人处理。

Q6：想修改模型参数或重新训练

编辑 `configs/config.yaml` 文件（可用记事本打开），修改相关参数后重新运行即可。建议在修改前备份原文件。

附录：项目文件结构

项目根目录/	
├── README.md	项目说明文档
├── 使用说明.pdf	本文件（操作指南）
├── requirements.txt	Python 依赖列表
├── configs/config.yaml	配置文件（随机种子、模型参数）
├── src/main.py	程序入口（运行此文件即可）
├── data/raw/	原始数据存放目录
├── results/	输出结果（图片）
└── notebooks/	Jupyter 探索笔记（进阶用户）